

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ  
им. Н.Э. Баумана

Кафедра «Систем обработки информации и управления»

Рубежный контроль №2  
по курсу «Методы машинного обучения»

Выполнил: Красавцев К.Ю.  
группа ИУ5-21М

Москва - 2020

---

## Задача №1. Классификация текстов на основе методов наивного Байеса.

Задание:

Необходимо решить задачу классификации текстов на основе любого выбранного Вами датасета. Классификация может быть бинарной или многоклассовой. Целевой признак из выбранного Вами датасета может иметь любой физический смысл, примером является задача анализа тональности текста.

Необходимо сформировать признаки на основе CountVectorizer или TfidfVectorizer.

В качестве классификаторов необходимо использовать один из классификаторов, не относящихся к наивным Байесовским методам (например, LogisticRegression), а также Multinomial Naive Bayes (MNB), Complement Naive Bayes (CNB), Bernoulli Naive Bayes.

Для каждого метода необходимо оценить качество классификации с помощью хотя бы одной метрики качества классификации (например, Ассурасу).

Сделайте выводы о том, какой классификатор осуществляет более качественную классификацию на Вашем наборе данных.

Датасет: <https://www.kaggle.com/edalrami/19000-spotify-songs>

Решение:

```
In [1]: import numpy as np
import pandas as pd
from typing import Dict, Tuple
from scipy import stats
from IPython.display import Image
from sklearn.datasets import load_iris, load_boston
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score, classification_report
from sklearn.metrics import confusion_matrix
from sklearn.model_selection import cross_val_score
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_absolute_error, mean_squared_error, mean_squared_log_error, median_absolute_error,
from sklearn.metrics import roc_curve, roc_auc_score
from sklearn.metrics import plot_confusion_matrix
from sklearn.metrics import balanced_accuracy_score
from sklearn.naive_bayes import MultinomialNB, ComplementNB, BernoulliNB
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
from sklearn.feature_extraction.text import TfidfVectorizer
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

```
In [2]: # Загрузка данных
messages = pd.read_csv("spam.csv")
messages = messages.iloc[:, [0, 1]]
messages.columns = ["class", "message"]
messages.head()
```

```
Out[2]:
```


	class	message
0	ham	Go until jurong point, crazy.. Available only ...
1	ham	Ok lar... Joking wif u oni...
2	spam	Free entry in 2 a wkly comp to win FA Cup fina...
3	ham	U dun say so early hor... U c already then say...
4	ham	Nah I don't think he goes to usf, he lives aro...

```
In [3]: messages.shape
messages=messages.fillna('0')
```

```
In [4]: messages['class'].unique()
```

```
Out[4]: array(['ham', 'spam'], dtype=object)
```

```
In [5]: plt.hist(messages['class'])
plt.show()
```



```
In [6]: # Сформируем общий словарь для обучения моделей из обучающей и тестовой выборки
vocab_list = messages['message'].tolist()
vocab_list[1:10]
```

```
Out[6]: ['Ok lar... Joking wif u oni...',
'Free entry in 2 a wkly comp to win FA Cup final tkts 21st May 2005. Text FA to 87121 to receive entry question(s
td txt rate)T&C's apply 08452810075over18's",
'U dun say so early hor... U c already then say...',
'Nah I don't think he goes to usf, he lives around here though",
'FreeMsg Hey there darling it's been 3 week's now and no word back! I'd like some fun you up for it still? Tb ok!
XX std chgs to send, â€1.50 to rcv",
'Even my brother is not like to speak with me. They treat me like aids patent.',
'As per your request 'Melle Melle (Oru Minnaminunginte Nurungu Vettam)' has been set as your callertune for all c
allers. Press *9 to copy your friends Callertune",
'WINNER!! As a valued network customer you have been selected to receivea â€900 prize reward! To claim call 09061
701461. Claim code KL341. Valid 12 hours only.',
'Had your mobile 11 months or more? U R entitled to Update to the latest colour mobiles with camera for Free! Cal
l The Mobile Update Co FREE on 08002986030']
```

```
In [7]: vocabVect = CountVectorizer()
vocabVect.fit(vocab_list)
corpusVocab = vocabVect.vocabulary_
print('Количество сформированных признаков - {}'.format(len(corpusVocab)))
```

Количество сформированных признаков - 8673

```
In [8]: tfidf = TfidfVectorizer(ngram_range=(1,3))
tfidf.ngram_features = tfidf.fit_transform(vocab_list)
tfidf.ngram_features
```

```
Out[8]: <5572x104567 sparse matrix of type '<class 'numpy.float64'>'
        with 216727 stored elements in Compressed Sparse Row format>
```

Будем проверять классификаторы *LinearSVC* и метод *К соседей*.

В качестве наивных Байесовских используем методы *Complement Naive Bayes (CNB)* и *Bernoulli Naive Bayes*.

Предположительно лучшую точность среди Байесовских классификаторов покажет *CNB*, поскольку данный метод подходит для наборов с сильным дисбалансом классов.

Проверим это предположение:

Разделим выборку на обучающую и тестовую.

```
In [9]: X_train, X_test, y_train, y_test = train_test_split(messages['message'], messages['class'], test_size=0.6, random_s
```

Будем использовать метрики качества *balanced\_accuracy* и матрицу ошибок.

```
In [10]: def accuracy_score_for_classes(
    y_true: np.ndarray,
    y_pred: np.ndarray) -> Dict[int, float]:
    """
    Вычисление метрики accuracy для каждого класса
    y_true - истинные значения классов
    y_pred - предсказанные значения классов
    Возвращает словарь: ключ - метка класса,
    значение - Accuracy для данного класса
    """
    # Для удобства фильтрации сформируем Pandas DataFrame
    d = {'t': y_true, 'p': y_pred}
    df = pd.DataFrame(data=d)
    # Метки классов
    classes = np.unique(y_true)
    # Результирующий словарь
    res = dict()
    # Перебор меток классов
    for c in classes:
        # отфильтруем данные, которые соответствуют
        # текущей метке класса в истинных значениях
        temp_data_flt = df[df['t']==c]
        # расчет accuracy для заданной метки класса
        temp_acc = balanced_accuracy_score(
            temp_data_flt['t'].values,
            temp_data_flt['p'].values)
        # сохранение результата в словарь
        res[c] = temp_acc
    return res

def print_accuracy_score_for_classes(
    y_true: np.ndarray,
    y_pred: np.ndarray):
    """
    Вывод метрики accuracy для каждого класса
    """
    accs = accuracy_score_for_classes(y_true, y_pred)
    if len(accs)>0:
        print('Метка \t Accuracy')
        for i in accs:
            print('{ } \t { }'.format(i, accs[i]))
```

```
In [11]: def sentiment(v, c):
  model = Pipeline(
    [("vectorizer", v),
     ("classifier", c)])
  model.fit(X_train, y_train)
  y_pred = model.predict(X_test)


  # Accuracy
  print_accuracy_score_for_classes(y_test, y_pred)

  # Матрица ошибок
  fig, ax = plt.subplots(figsize=(15,5))
  plot_confusion_matrix(model, X_test, y_test, cmap=plt.cm.Blues, ax=ax)
```

```
In [12]: sentiment(TfidfVectorizer(ngram_range=(1,3)), LinearSVC())
```

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

```
Метка Accuracy
ham 0.997571973638571
spam 0.8763557483731019
```



```
In [13]: for k in range(1, 15):
  print(k)
  sentiment(TfidfVectorizer(ngram_range=(1,3)), KNeighborsClassifier(n_neighbors=k))
```

1

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

```
Метка Accuracy
ham 1.0
spam 0.4685466377440347
```

2

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

```
Метка Accuracy
ham 1.0
spam 0.19305856832971802
```

3

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

```
Метка Accuracy
ham 1.0
spam 0.19305856832971802
```

4

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

```
Метка Accuracy
ham 1.0
spam 0.08459869848156182
```

5



```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

Метка	Accuracy
ham	0.9986125563648977
spam	0.6464208242950108

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

Метка	Accuracy
ham	1.0
spam	0.5553145336225597

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

Метка	Accuracy
ham	0.9986125563648977
spam	0.6529284164859002

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

Метка	Accuracy
ham	0.9996531390912244
spam	0.6117136659436009

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

Метка	Accuracy
ham	0.9986125563648977
spam	0.6789587852494577

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

Метка	Accuracy
ham	0.9993062781824489
spam	0.6290672451193059

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

Метка	Accuracy
ham	0.9982656954561221
spam	0.6832971800433839

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

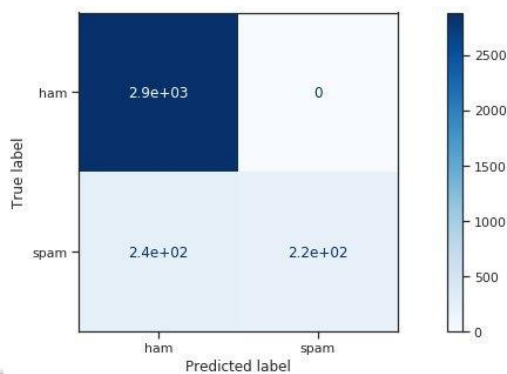
Метка	Accuracy
ham	0.9993062781824489
spam	0.6377440347071583

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```

Метка	Accuracy
ham	0.9993062781824489
spam	0.6616052060737527

```
/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/_classification.py:1859: UserWarning:
y_pred contains classes not in y_true
warnings.warn('y_pred contains classes not in y_true')
```


Метка	Accuracy
ham	0.9996531390912244
spam	0.6182212581344902



```
In [14]: # Лучшее значение - 3 соседа
sentiment(TfidfVectorizer(ngram_range=(1,3)), KNeighborsClassifier(n_neighbors=14))
```

/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/\_classification.py:1859: UserWarning: y\_pred contains classes not in y\_true  
warnings.warn('y\_pred contains classes not in y\_true')


Метка	Accuracy
ham	0.9996531390912244
spam	0.6182212581344902



```
In [15]: sentiment(TfidfVectorizer(), ComplementNB())
```

/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/\_classification.py:1859: UserWarning: y\_pred contains classes not in y\_true  
warnings.warn('y\_pred contains classes not in y\_true')

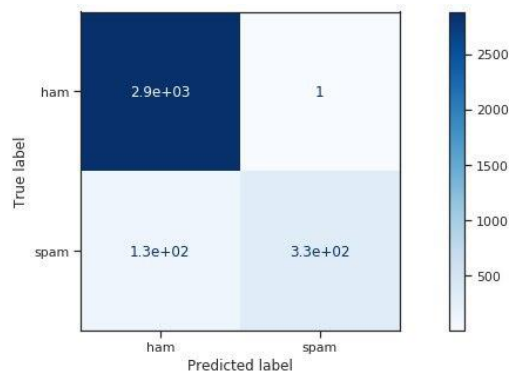
Метка	Accuracy
ham	0.9895941727367326
spam	0.8308026030368764



```
In [16]: sentiment(TfidfVectorizer(), BernoulliNB())
```

/home/kirill/anaconda3/envs/mmo/lib/python3.8/site-packages/sklearn/metrics/\_classification.py:1859: UserWarning: y\_pred contains classes not in y\_true  
warnings.warn('y\_pred contains classes not in y\_true')

Метка	Accuracy
ham	0.9996531390912244
spam	0.720173535791757



## Вывод:

Поскольку выборка несбалансированная и все классификаторы делают незначительное количество ошибок при предсказании класса ham(не спам), то будем смотреть точность, с какой модели предсказывают класс spam. Можно увидеть, что наилучший результат показал классификатор LinearSVR, а худший - метод К соседей с 13 соседями(также был проведен эксперимент, определяющий оптимальное кол-во соседей, но даже при этом этот метод оказался худшим). Так же было подтверждено предположение, что лучшую точность среди Байесовских классификаторов покажет CNB, так как он предназначен для классов с дисбалансом.